

정적 언어모델부터 생성형AI까지, 텍스트를 다시 쓰는 기술에 대하여

— 조은경, 『한국학과 데이터과학』(서강대학교출판부, 2024) —

전성규*

조은경의 『한국학과 데이터과학』은 “어문 및 인문학 연구자에게 활용도 높은 데이터 과학적 연구방법론을 안내함으로써” 한국 문학 및 문화 연구를 디지털인문학 방법론을 수행하고자 하는 연구자에게 실질적인 도움을 줄 수 있는 책이다. 디지털인문학은 데이터 분석의 프로토콜을 포함하지만 단순한 기술 활용을 넘어 철학적, 문화적 전환을 내포하는 광범위한 개념으로 사용되기도 한다. 이 과정에서 생산되는 관련 논문이나 논의들은 답변성이 강하게 나타나거나 기술 사용 과정이 간소화되는 경우가 있는 것도 사실이다. 조은경은 ‘데이터과학’이라는 용어를 채택함으로써 한국어 기반 언어 자료를 수집하고 처리하여 분석하는 데 필요한 구체적인 기술과 절차에 보다 초점을 맞추고 있다.

디지털인문학에서 가장 활발하게 수행되는 연구 중 하나는 문자 기반 텍스트에 대한 분석이다. 그렇기 때문에 이 책 또한 “데이터의 양적 분석에 쓰이는 기초 통계량에서부터 딥러닝에 이르기까지”를 차근차근 설명하고 있다. 비정형 데이터의 비중이 증가함에 따라 평균, 표준편차, 분산 등 전통적인 기술통계량만으로는 데이터가 내포한 복잡한 의미 구조나 맥락적 관계를 충분히 설명하기 어려운 점이 있으므로 고차원 벡

터 기반 지표들을 요청하게 되었으며 더 나아가 딥러닝 언어모델에 기반하여 “문맥에 따라 벡터 값이 변하는 동적 벡터”를 활용, 단어 수준을 넘어 문장, 문맥, 최종적으로 텍스트 수준에서 의미가 생성되는 과정을 다차원 벡터 공간에서 정교하게 표현하려는 시도들이 이어지고 있다. 또한 GPT와 같은 생성형 언어 모델을 인문학 연구와 결합하기 위해 RAG이나 온톨로지 기반 모델링을 활용하여 특정 분야의 전문 데이터를 추가학습함으로써 특정 도메인에 특화된 지식 생성의 정확도를 향상하려는 시도가 활발하다.

저자가 서술하는 데이터과학의 방법론적 변화 과정의 흐름을 따라가다 보면 이는 곧 디지털인문학의 자기 갱신 과정임을 알게 된다. 정적 언어 모델에서부터 동적 언어 모델로의 이행, 초대규모 언어 모델의 인문학적 활용 방식에 대한 모색은 인문학 텍스트가 지닌 의미적 중층성을 중심에 두고 기술을 비판적으로 사유하는 자세에서 비롯된 것이다. 기술의 발전 속도가 빠르게 변화하는 가운데 인문학 연구자들이 그 속도를 앞서거나 발맞춰 따라가는 것은 쉬운 일이 아니다. 오히려 조은경은 인문학연구자가 기술에 대한 풍부한 감각을 확보하고 분석의 맥락에 따라 기술을 사유하는 능력이 더 중요하다는 점을 보여주고 있다. 텍스트와 기술 사이의 창조적인 매핑을 모색하고 이를 통해 해석과 판단이 개입된 지식 생산의 실천으로 나아가는 것이 디지털인문학, 인문데이터과학이 추구하는 방향성이라는 점을 보여준다.

이와 같은 흐름을 따라가며 서평을 쓰는 필자는 추가적으로 데이터셋 구성의 중요성과 텍스트가 기술, 데이터셋 등을 통해 새롭게 표상됨으로써 열리는 글쓰기의 가능성, 연구자의 정체성의 변화에 대해 언급하였다. 디지털인문학 연구는 기술과 연구자, 텍스트와 연구자 등 다양한 차원에서 공동 저작성의 워크플로우를 포함하고 있다. 또한 기술이 가진 무한한 문장 생성의 가능성을 통해 의미를 끝맺는 기존의 문학과 예술의 의례에서 이탈하는 글쓰기 양식을 모색할 수 있다. 이 문장들은 때때로 무의미의 경계를 뚫으며 규범 바깥의 언어조각들로 구성되기도 한다. 의미로 회수되지 않는 언어의 조각들이 무작위로 배치되는 것을 목도하며 그 혼돈 속에서도야말로 새로운 문학을 상상할 수 있는 길이 열림을 감각할 수 있다.

논문 분야: 디지털인문학

주제어: 데이터과학 연구방법론, 디지털인문학, 정적 언어모델, 동적 언어모델, 생성형 언어모델, 지식생산모델링, 텍스트와 기술 간 창조적 맵핑, 다층적 차원의 공동저작성, 중단없는 글쓰기, 차연(différence)

1. 데이터과학이라는 용어의 선택

조은경의 『한국학과 데이터과학』(서강대학교출판부, 2024)은 연구자가 서문에서 밝히고 있듯 “어문 및 인문학 연구자에게 유익하고 활용도가 높은 데이터과학적 연구 방법론을 안내함으로써 한국학 및 어문학 연구 방법론과 연구 주제의 지평을 넓히는 참고가 되도록”¹하는 것에 목적을 두고 있다.

디지털인문학이라는 연구방법론은 2010년대를 전후로 하여 한국문학 및 문화 연구에 새로운 연구 방법론으로 제안되었으며 이후 이를 활용한 연구 성과들이 본격적으로 발표되기 시작하였다. 초기에는 디지털 도구의 기술적 활용에 초점이 맞춰졌으나, 점차 비판적 읽기와 해석학적 실천으로 연구의 성숙도가 높아지고 있는 상황이다.

디지털인문학에서 가장 활발히 수행되는 작업 중 하나는 문자 기반 텍스트에 대한 분석이다. 그러나 디지털인문학은 문자로 이루어진 텍스트 분석에 국한되지 않는다. 비문자적 텍스트로 분석 대상을 확장하거나 문자 텍스트를 비문자적 형식으로 변환하거나 그 역의 과정을 수행하는 것 또한 적극적으로 수용한다. 이미지, 영상, 지도, 사운드와 같은 비정형적 자료들은 디지털 기술을 통해 구조화되고 해석 가능해지며 문자 텍스트로 구성된 정형적 자료 역시 시청각적이고 감각적인 매체로 재구성될 수 있다. 이는 디지털인문학이 ‘멀티모달 인문학’으로 진화하고 있음을 보여준다.

디지털인문학은 데이터분석의 프로토콜을 포함하지만 단순한 기술 활용을 넘어서 철학적, 문화적 전환을 내포하는 광범위한 개념으로 사용

1 조은경, 2024, 『한국학과 데이터과학』, 서강대학교출판부, 5쪽.

되기도 한다. 기술의 사용이 단순히 기존의 지식을 보강하는 방식으로 그치지 않고 기존의 지식 생산 방식이 포착하지 못했던 대상과 의미를 새롭게 드러내는 방법론이 되어야 한다는 지식사회의 요청은 바로 이런 맥락에서 비롯된다. 디지털인문학 스스로도 이러한 담론적 전환을 사명으로 삼고 있기 때문에, 관련 논문들 역시 담론성이 강하게 나타나는 경우가 있으며, 지면의 제약 등으로 인해 기술 사용 과정을 간소화하고 해석의 차원에 집중하는 경향이 있는 것도 사실이다. 이 과정에서 해당 기술이 어떤 원리에 기반하여 작동하는지 실제로 그것을 어떻게 활용할 수 있는지에 대한 기초적인 정보를 충분히 제공 받기 어려운 측면도 있다.

이와 같은 맥락에서 조은경이 ‘데이터과학’이라는 용어를 채택한 이유를 생각해 볼 필요가 있다. 디지털인문학은 그 자체가 이론적, 기술적, 문화적, 제도적 의미가 복합적으로 얹힌 다층적 개념으로 기술적 측면조차도 기술 그 자체만을 지칭하기보다는 인문학적 해석과 연결된 보다 복합적인 맥락 속에서 이해되곤 한다. 반면 데이터과학은 디지털인문학이 갖는 개념적 다의성과 포괄성에서 약간의 자율성을 가지며 한국어 기반 언어 자료를 실질적으로 수집하고 처리하여 분석하는 데 필요한 구체적인 기술과 절차에 초점을 맞출 수 있는 용어이다. 조은경의 책은 인문학 연구자가 데이터를 직접 다루는 데 필요한 기술적 역량을 어떤 방식으로 습득하고 실행에 옮길 수 있는지를 상세히 제시한다는 점에서 데이터과학이라는 용어 선택이 설득력 있게 다가온다.

위에서 언급한 것처럼 이 책은 데이터를 스스로 다룰 수 있는 능력을 갖추고자 하는 인문학자를 위한 실질적인 안내서이다. 이와 같은 목적은 디지털 기술이 연구의 전 과정에 깊숙이 개입하고 있는 현재의 연구 환경을 고려할 때 매우 의미 있는 시도라고 평가할 수 있다. 디지털 기술

을 활용한 다수의 디지털인문학 논문들은 특정 도구나 분석 기법에 대한 사전 지식을 독자 역시 보유하고 있을 것이라는 전제 아래 서술되어 있는 경우가 있어 입문자나 비전공자에게는 진입장벽을 형성하며 해당 논의에 참여하기 어려운 상황을 초래한다. 또한 연구자의 입장에서 기술을 다루는 것이 익숙하지 않을 경우 결국 기술 사용을 포기하거나 기술을 다룰 수 있는 외부 인력에 의존해야 할 수밖에 없어 분석을 포기하거나 분석의 과정에서 소외될 위험이 높다. 이는 연구자가 자신의 연구를 기획하고 실행하는 데 있어 자율성과 통제력을 확보하기 어렵게 만드는 요인이기도 하다. 이러한 점에서 조은경의 책은 인문학 연구자들이 기술을 이해하고 구사함으로써 연구의 기획, 수행, 분석의 전 과정을 주도할 수 있도록 돕는 매뉴얼로 역할할 수 있다. 이는 연구자가 자신의 연구를 통제해나가며 연구 주권을 확보하는 데 기여한다는 점에서 그 의의가 적지 않다.

하지만 그럼에도 불구하고 ‘국어정보학’² 연구성과를 주로 참고하여 한국학 연구의 데이터과학 방법론을 안내하는 이 책은 일정한 한계를 드러낸다. 데이터과학이라는 개념을 통해 실천적 방법론을 부각하려는 시도는 충분히 유용하지만 이 책이 상정하는 독자층이 단지 한국학 자

2 조은경에 따르면 국어정보학은 이제 잘 쓰지 않는 학문명칭이다. 그러나 저자는 이 학문이 사회적으로 비판을 받는 지점을 성찰하면서도 그 학문이 지니는 본질적인 매력과 학문적 가능성을 긍정적으로 평가한다. 나아가 국어정보학이 갱신해야 할 지점과 이 분야에 종사하는 연구자들에게 요청되는 자질과 태도에 대해서도 함께 모색하고 있다. 조은경, 2024, 앞의 책, 337~338쪽. “필자가 전공한 국어정보학은 이미 죽은 학문이라 평가하는 말을 종종 듣는다. 이 전공 명칭으로 학위를 받고 연구 활동을 하고 있는 당사자로서 필자는 매우 충격적이고 연구 활동에 대해 반성을 하게 된다. ... 국어정보학 연구자가 컴퓨터를 잘 다루지 않고 데이터만 구축하는 일을 하는 것은 데이터의 중요성이 크다 할지라도 연구 용역만 수행할 수밖에 없는 현실을 만들어가는 일이라고 생각하기 때문에 반드시 데이터 분석 및 응용과 같이 가야 한다고 생각한다.”

료를 분석 대상으로 삼고자 하는 국어학자나 언어정보학자에 국한되지 않고 인문학 전반에 걸쳐 다양한 문제의식과 분석 대상을 지닌 문화 연구자, 문학 연구자를 포함하고 있다는 점에서 보다 넓은 범주의 접근이 필요하다. 특히 문화 및 문학 연구자들이 디지털 기술이나 언어처리 기술을 어떠한 방식으로 연구에 적용하고 있는지 그로부터 도출되는 지식과 해석이 기존의 것과 어떻게 관계하는지를 함께 검토하지 않는다면 데이터과학이라는 실천적 개념은 기술 중심의 활용으로만 축소될 위험이 있다.³

-
- 3 지면을 빌려 디지털인문학의 방법론을 통한 문화사적, 매체사적 연구성과를 기입해 보고자 한다. 2000년대 초반부터 한국 역시 인문학과 디지털기술의 결합을 시도해 왔으며 그 성과가 산업적으로 활용될 수 있도록 '문화콘텐츠'라는 새로운 분야를 개척했다. 그러나 이 과정에서 인문학자와 디지털기술을 구사하는 전문가 간의 유리가 두드러지게 되었고 이것이 인문학 자료의 올바른 맥락화를 저해할 수 있다는 우려가 제기되었다. 이러한 문제의식 속에서 디지털인문학은 인문학자가 기술 활용의 주체가 되는 것을 핵심 과제로 삼았으며 인문학적 통찰을 바탕으로 디지털 기술을 적용한 다양한 연구성과를 도출하는 것을 목표로 해왔다. 이를 위해 여러 디지털인문학 프로그램이 기획, 운영되어 인문학자의 기술 역량 강화를 위한 시도가 지속되어 왔다. 홍정욱·김기덕, 2014, 「2014 세계 디지털인문학」 학술대회 및 한국의 디지털인문학, 『인문콘텐츠』 34, 인문콘텐츠학회, 53~75쪽. 데이터베이스를 만들어 디지털인문학의 기반을 형성하고 그 위에 수량적 분석의 방법론, 네트워크 분석, 워드 임베딩, 토픽모델링 등의 방식을 활용하여 텍스트에 내재된 문화적·문학적 의미구조를 분석하려는 시도가 이루어졌다. 관련 연구성과를 간단히 정리하면 다음과 같다. 말뭉치 등 데이터분석에 활용할 수 있는 텍스트 데이터 확보에 대해서는 김일환·이도길, 2020, 「개화기 잡지 코퍼스의 구축과 활용」, 『개념과 소통』 25, 한림대학교 한림과학원, 5~31쪽; 도재학, 2022, 「『한국근대잡지코퍼스』의 언어학적 가치」, 『개념과 소통』 29, 한림대학교 한림과학원, 7~43쪽; 이성우, 2022, 「『한국근대잡지코퍼스』로 엮보는 한국의 근대: 키워드와 빈도를 중심으로」, 『개념과 소통』 29, 한림대학교 한림과학원, 45~79쪽. 이 외에 한국사데이터베이스 잡지 원문 자료 등 연구 기반 자료를 대상으로 문학, 문화, 역사 등의 인문학적 지식과 교호하는 근대 한국학 성과들이 적지 않게 축적되었다. 이재연, 2016a, 「키워드와 네트워크: 토픽모델링으로 본 『개벽』의 주제 지도 분석」, 『상허학보』 46, 상허학회, 277~334쪽; 이재연, 2016b, 「생활'과 '태도' 기제가 읽은 『개벽』과 『조선문단』의 작품 비평어와 비평가」, 『개념과 소통』 18, 5~52쪽; 허수, 2018, 「언어연결망 분석으로 본 20세기 초 한국의 '문명'과 '문화': 주요 언론 기사에서의 논의 맥락을 중심으로」, 『개념과 소통』 22, 한림대학교 한림과학원,

2. 데이터과학의 방법론적 변화 과정, 정적 데이터에서 생성형 언어모델까지

이 책의 전반부는 저자가 말했듯이 “데이터과학적 방법론에 관한 것으로 획득이 가능한 디지털 데이터를 소개하고 프로그래밍 방법을 활용하여 단기간에 많은 양의 데이터를 수집하는 방법을 안내한 후, 이러한 데이터를 양적으로 다루고 모델링하기 위한 이론적인 내용과 구체적인 실행과정을 소개”하는 데에 중점을 둔다.⁴ 책의 구성은 “연구 목적으로 데이터를 활용하고자 할 때 데이터를 조회하거나 내려받을 수 있도록 웹으로 서비스하는” 인터넷 자원에 대한 탐색에서 출발하여, 데이터 종류에 대한 구분, 데이터를 웹에서 수집하는 방법을 소개하는 것으로 전개된다.

기초적인 관점에서 이 책이 지니는 장점 중 하나는 코엔엘피와이(KoNLPy)와 같은 라이브러리, 모듈, 실행 환경 등의 영어명을 한글로 함께 표기한다는 것이다. 이와 같은 한글 음차 병기는 입문자를 중심 독자로 상정하

241~297쪽: 전성규·김병준, 2019, 「디지털인문학 방법론을 통한 『서북학회』와 『태극학보』의 담론적 상관관계 연구」, 『개념과 소통』 23, 한림대학교 한림과학원, 141~188쪽; 이유미·김바로, 2022, 「사회 네트워크 분석을 활용한 1930년대 후반 동인지(詩誌)와 시인」, 『인문논총』 79, 인문학연구원, 212~245쪽. 그 밖에 인공지능 시대의 인문학연구의 방향을 논의한 연구로 김병준·노대원, 2025, 「생성형 AI는 인문학 연구를 어떻게 바꿀까?」, 『영주어문』 59, 영주어문학회, 203~227쪽 등이 있으며 인문학 텍스트를 대상으로 비문자적 미디어를 생산하는 방법 등 멀티모달적 관점에서 분석한 연구로 전성규, 2024, 「이광수의 오감(五感) 오케스트레이션 - 소리 데이터 생산과 미디어 교차 중심으로」, 『춘원연구학보』 29, 춘원연구학회, 73~109쪽 등이 있다. 대표적인 디지털인문학 교육프로그램으로는 한국디지털인문학협의회(KADH)에서 매년 개최하는 디지털인문학 학교 등을 예로 들 수 있을 것이다. <https://www.kadh.org/2025-디지털인문학-겨울학교/>

4 조은경, 앞의 책, 21쪽.

고 있다는 것을 보여주며 기술 학습에 대한 심리적 거리감을 줄이고 독자가 능동적으로 탐색하고 실험할 수 있는 학습 환경을 만드는 데에 기여한다. 또한 JSON, HTML과 같은 데이터 구조화 형식들에 대한 기초적인 설명을 풍부하게 제공하여 웹 기반 데이터 구조에 대한 이해를 돕고 해당 데이터를 어떤 방식으로 파싱하고 활용할 수 있는지에 대한 실질적 감각을 제공한다.

제3부 <데이터 분석 방법론>부터 본격적으로 “데이터의 양적 분석에 쓰이는 기초 통계량에서부터 딥러닝에 이르기까지 여러 가지 방법론”을 설명하고 있다. 최근 텍스트, 이미지, 음성 등 구조화되지 않은 비정형 데이터의 비중이 증가함에 따라 평균, 표준편차, 분산 등의 전통적인 기술통계량만으로는 데이터가 내포한 복잡한 의미 구조나 맥락적 관계를 충분히 설명하기 어려운 점이 있다. 이 과정에서 상호정보량(Mutual Information), 코사인유사도, TF-IDF와 같은 지표들이 활발히 사용되고 있으며 이 책은 이와 같은 기술 도입의 동시대적 맥락과 분석적 효용성을 짚어가며 차근차근 설명해 나간다.

형태소 분석을 포함한 토큰화를 설명하는 대목에서 저자는 토큰화 자체가 중립적인 절차가 아니라 연구자의 연구목적과 문제의식이 개입된다는 점을 강조한다. 분석에서 어떤 단어를 의미 있는 정보로 간주할 것인가 불필요한 단어로 배제할 것인가, 혹은 분석 단위를 어떻게 설정할 것인가, 예컨대 복합어를 분할하여 볼 것인가 하나의 단위로 처리할 것인가, 단어를 조사와 결합해 분석할 것인가 아니면 분리해서 분석할 것인가와 같은 결정들은 모두 연구자가 설정한 분석 목표에 따라 달라진다. 예를 들어 책에 수록된 <그림 3.70> ‘2018년 여성과 남성의 임베딩 시각화’를 살펴보면 ‘여성’, ‘남성’, ‘여성의’, ‘남성의’, ‘여성이’, ‘남성이’와 같은 어형들이 서로 다른 임베딩 벡터를 형성하며 의미 공간에서 다른

위치에 분포하고 있음을 확인할 수 있다.⁵ 얼핏 보면 명사 뒤에 붙은 조사를 제거해야 하는 것이 적절하다고 생각할 수 있으나 ‘의’나 ‘이’와 같은 조사가 문장 내에서 갖는 의미적 기능이 맥락 형성에 영향을 주기 때문에 상이한 분포 양상을 보이게 됨을 확인할 수 있는 부분이다.

이 책은 텍스트 전처리 과정과 TF-IDF와 같이 텍스트 데이터를 수치화하는 기술에 대한 설명을 거쳐 머신러닝과 딥러닝을 활용한 자료 분석 방법론으로 나아간다. 대표적으로 나이트베이지와 같은 지도학습과 LDA토픽모델링, K-평균군집분석과 같은 비지도학습 방법을 소개하고 있다. 특히 LDA와 K-평균군집분석과 같은 비지도학습 방법은 단어간 공동 등장 빈도와 문서 내 분포에 기반하여 단어 또는 문서를 ‘확률적’으로 묶어내는 방법으로 대량의 문서에서 잠재적인 주제 구조나 문서 간 관계성을 파악하는 데에 용이하다. 다만 책에서 지적한 바대로 이들 방법은 단어가 사용된 어순이나 맥락적 의존성을 고려하지 않기 때문에 어휘적으로는 유사하지만 문맥적으로는 상이한 의미를 갖는 단어들이 동일한 군집에 포함되는 문제가 발생할 수 있다.

이와 같은 단어 임베딩의 한계를 보완하기 위해 문장 임베딩, 더 나아가 문맥 임베딩(contextual embedding) 기술이 활용되고 있다. 문맥 임베딩은 “단어의 주변 문맥에 따라 벡터 값이 변하는 동적 벡터”⁶로 표현이 가능하여 유사한 단어군이 사용되었어도 각각이 놓인 문맥에 따라 의미적 차이를 벡터로 반영할 수 있는 표현방식이다. 유사한 단어들이라도 의미상 서로 다른 맥락에 놓여 있다면 그 차이가 벡터값에 반영되어 더 정교한 유사도 계산이 가능해진다. 대표적으로 서브워드(subword) 정보

5 조은경, 2024, 앞의 책, 176쪽.

6 조은경, 2024, 앞의 책, 181쪽.

를 반영하여 문장 내 어휘 관계를 동적으로 파악할 수 있는 트랜스포머(transformer) 기반 언어모델을 예로 들 수 있다.⁷ 서브워드는 단어보다 작은 문자 단위이지만 문맥을 바꿔내는 역할을 수행하는 미세 단위의 언어 정보들을 데이터처리에 반영할 수 있게 해준다. 특히 한국어처럼 교착어적 특성을 지닌 언어에서는 의미 변화가 어미나 조사 등의 결합을 통해 발생하는 경우가 많기 때문에 서브워드 기반 분석이 문맥을 정밀하게 분석하는 데 효과적인 것이다.

대표적으로 재현신경망(RNN)에 기반한 언어모델의 한계를 보완한 트랜스포머 언어모델은 문맥 수준을 고려할 수 있는 구조를 갖추고 있다. 트랜스포머의 셀프 어텐션(self-attention)은 입력된 문장을 서브워드 단위로 분절한 후 이 단위들 간의 상호관계를 동시참조하여 학습한다. 이 과정은 쿼리(Query), 키(Key), 값(Value) 벡터 간의 연산을 통해 이루어진다. 이 책에서는 셀프 어텐션의 개념을 확장하여 멀티헤드 어텐션(multi-head attention)의 중요성을 강조한다. 멀티헤드 어텐션이란 셀프 어텐션을 병렬적으로 여러 개 두어 “언어의 다면적 속성을 모델링”하는 방법이다.⁸ 하나의 어텐션이 포착하지 못하는 복합적인 의미 구조나 중첩된 언어 관계들을 여러 개 어텐션 헤드를 통해 파악하는 방법이다. 이와 같은 문맥 수준을 다각도로 고려하여 언어의 다면적 속성을 모델링하는 방법은 특히 ‘문학’ 텍스트 분석에 적합하다.⁹ 문학어는 기존의 언어 질서를

7 어수경·박찬준·문현석·임희석, 2021, 「한국어 인공지능경망 기계번역의 서브 워드 분절 연구 및 음절 기반 종성 분리 토큰화 제안」, 『한국융합학회논문지』 12, 한국융합학회, 1~7쪽.

8 조은경, 2024, 앞의 책, 183~184쪽.

9 강우규·김바로, 2024, 「국문장편소설의 감정에 대한 정성적·정량적 연구 시론 - 「창선감의록」과 「소현성록」을 중심으로」, 『고소설연구』 58, 한국고소설학회, 223~258쪽. 강우규와 김바로는 인터넷 댓글을 대상으로 현대인들의 감정 식별 작업을 할 수 있는 감정분

변형하거나 새로운 언어 질서를 창안하는 방식으로 작동한다. 동일한 어휘라 하더라도 다양한 문맥 속에서 의미가 풍부해지면서 일상어의 계열 성과는 상이한 텍스트 고유의 의미 계열성을 형성하기도 한다. 이러한 문학 텍스트의 복잡한 의미 생성 구조를 추적하고 해석하기 위해서는 문맥 중심적이고 입체적인 언어모델링이 가능한 멀티헤드 어텐션과 같은 메커니즘이 요청된다고 볼 수 있다.

딥러닝 기반 언어 모델인 RNN이나 트랜스포머는 자연어를 수치화된 벡터로 표현하고, 이 수학적 계산 단위들을 연결하는 파라미터(parameter)를 조정하며 언어 구조를 학습해 나간다. GPT, LLAMA, Gemini, HyperClova 등의 초거대 언어 모델(LLM)은 트랜스포머 구조를 기반으로 수십억에서 수천억 개 이상의 파라미터를 보유한 모델들이다. 이와 같은 대규모 파라미터는 방대한 문장을 벡터 공간에서 처리하면서 단어 들 간의 관계성이나 문맥상의 자연스러움을 정교하게 학습하고 강화하는 데에 기여한다. 거대 언어 모델에는 다양한 아키텍처가 존재하는데 그중 가장 널리 사용되는 GPT(Generative pre-trained transformer)는 “다음 단어 생성(generation)에 집중하여 새로운 연속 단어에 대한 가능성(likelihood)을 학습한 생성형 모델이다.” 반면 트랜스포머 구조를 기반으로 한 바트(BERT) 계열 모델은 “범주 분류나 문맥 내 적합한 단어를 추정”하는 것과 같은 판별 모형(discriminative models)의 종류이다.¹⁰ 간단히 말해 판별 모형은 문장 내 빈칸을 채우는 방식에 적합하고 생성 모형은 “관측된 데이터로부터 학습한 모델에 기반하여 학습 데이터에는 실

석기 KOTE를 개발하였다. KOTE는 한국어에 특화된 BERT류 모델을 기반으로 감정 분석을 수행한다. <https://github.com/searle-j/KOTE>.

10 조은경, 2024, 앞의 책, 198쪽.

재하지 않지만 실제로 가까운 것을 생성(generate)하는 것”(198)에 중점을 둔다. GPT는 입력된 문장의 왼쪽에서 오른쪽 방향으로 언어를 생성해 나가는 구조이기 때문에 텍스트 생성, 요약, 번역 등의 작업에서 뛰어난 역량을 발휘한다. 그러나 이러한 생성형 구조는 모델 내부의 통계적 연관성에 기반하여 답을 내놓기 때문에 제출된 정보가 사실과 다른 경우도 많다. 흔히 말하는 환각현상(hallucination)은 생성형 모델이 갖는 구조적 특성과 밀접한 부작용이라고 말할 수 있다.

이러한 한계를 보완하기 위해 다양한 정밀조정(fine tuning)이 연구되고 있다. 특히 특정 분야의 전문 데이터를 추가 학습함으로써 특정 도메인에 특화된 지식 생성의 정확도를 향상하려는 시도가 활발하다. 이 과정에서 개념 간 관계망을 구조화하여 신뢰도 높은 응답을 생성하려는 온톨로지 기반 모델링도 주목받고 있다. 보다 범용적인 방법으로는 검색 확장 생성(RAG, Retrieval Augmented Generation)이 활용되고 있다. 검색 확장 생성은 생성 직전에 검색 엔진을 활용하거나 정적인 지식 베이스에서 검색 단계를 거쳐 사실성이나 신뢰성 검증을 거친 다음에 생성하는 방식¹¹⁾으로 사전학습된 모델이 자체적인 기반만을 사용하지 않고 외부의 검증된 정보와 결합하는 방식으로 학습하여 신뢰도를 높이는 구조를 갖는다.¹²⁾

11 배용준, 2025, 「검색증강생성(RAG)에 관한 국내 연구 동향」, 『한국융합학회지』 14, 한국융합학회, 407~421쪽. LLM의 환각 현상을 최소화할 수 있는 효과적인 방법인 검색증강생성에 대한 국내 관심은 2023년부터 급증하고 있다.

12 RAG을 결합한 파이프라인을 통해 도메인 특화형 커스텀 GPT를 만들려는 시도가 최근 활발히 이루어지고 있다. 예를 들어 2024년 12월 13일에 열린 <KADH 2024 디지털인문학대회: 디지털인문학의 넓이와 깊이>에서는 학술 발표 외에 여러 대학 학부생들의 디지털 인문학 연구 포스터 발표가 함께 진행되었는데 다수의 발표가 특정 분야에 전문화된 커스텀 GPT를 만드는 것이었고 그 과정에서 RAG기술이 핵심적으로 사용되었다. 아래 예시는 한림대학교 영어영문학과 허재은 학생의 발표 내용으로 셰익스피어의 삶과

저자가 데이터과학의 방법론적 변화 과정을 서술하는 흐름을 따라가다 보면 이는 곧 디지털인문학의 자기 갱신 과정임을 알게 된다. 정적 언어 모델에서부터 동적 언어 모델로의 이행, 초대규모 언어 모델의 인문학적 활용 방식에 대한 모색은 인문학 텍스트가 지닌 의미적 중층성을 중심에 두고 기술을 비판적으로 사유하는 자세에서 비롯된 것이다. 맥락 의존성이 강한 인문학 텍스트는 단순한 의미 연결망이나 빈도 기반의 분석만으로는 충분히 설명되지 않으며 단어와 문장의 관계, 텍스트 내부의 반복 구조, 환유와 은유의 계열을 정교하게 분할하고 다층적 차원으로 교차 검토할 수 있는 도구가 필요하다. 특히 문학, 철학, 역사 그리고 문화를 다루는 텍스트에서 확인할 수 있는 언어적 모호함, 잠재적 의미의 층위를 동적 모델 및 생성형 모델로 분석하는 작업은 텍스트 내부의 의미가 만들어지는 과정을 추적하고 재현하는 데 유용한 방법이 될 수 있다. 또한 특정 분야의 도메인 지식을 활용하여 생성형 언어 모델을 정밀 조정하는 방법을 활용하여 문학 텍스트는 비평, 역사적 문맥, 문학사적 흐름과 관련한 다양한 지식 파이프라인과 결합할 수 있다. 비평사적 맥락, 역사적 맥락, 문학사의 계보 등을 구조화한 파이프라인이 구축되면 해당 텍스트가 문학사, 비평사, 문화사 속에서 어떤 좌표를 갖는지를 체계적으로 파악할 수 있을 것이다. 문학 텍스트를 중심으로 한 지식 생산 모델링은 그간 인문학이 방대하게 축적해 온 고유의 해석적 실천을 계승하는 동시에 디지털 기술을 활용하여 연산 가능한 형태로 전환함으로써 구조적 재현 가능성을 갖추고 지식 생산의 잠재성을 지닌 연구 인프라로 기능할 수 있다.

작품에 대한 정확도 높은 데이터베이스를 구축한 뒤 이를 바탕으로 LLM이 신뢰도 높은 응답을 생성할 수 있도록 설계된 '세익스피어 챗봇' 프로젝트이다. <https://excessive-fowl-713.notion.site/feat-RAG-136708dbce8780109023d574f5253496>.

3. 공동저작의 다층적 지형

정적 언어 모델에서 동적 언어 모델로, 판별형 모델에서 생성형 모델로 기술은 진화를 거듭하고 있지만 조은경이 제시하는 기계기술에 대한 관점은 보통의 선형적 서사와 그 결을 달리한다. 저자는 “정적 단어 임베딩이 최신의 인공지능 언어 모델에서는 다소 유행에 뒤떨어진 감이 있지만 닫힌 정적 데이터 집합을 다룬다는 점에서 언어학적으로 인문학적으로는 여전히 살펴볼 여지가 많은 방식”¹³이라고 본다. 초거대 언어 모델, 생성형 인공지능이 기술의 전면에 부상한 지금 정적 언어 모델은 뒤쳐진 기술, 낡은 도구일지 모른다. 그러함에도 그 기술들은 특정한 분석 목적에 따라 여전히 유효한 의미를 갖는다. 특히 정적 단어 임베딩은 단어 간 의미 관계를 고정된 벡터 공간에서 안정적으로 비교하고 전체 데이터셋의 구조를 명료하게 시각화할 수 있는 장점이 있다. 동적 언어 모델과 무작위성을 내포한 최신의 모델들이 포착하지 못하는 의미구조를 안정적으로 확보하는 데 유용하게 역할을 할 수 있는 것이다. 더 나아가 인문학의 주요 연구경향이 예측이나 생성이라기보다 언어의 구조, 의미의 반복을 통한 계열성의 분석과 같이 어휘 분포를 재귀적으로 구성하는 것에 있다고 할 때 정적 모델은 분석의 깊이를 확보하는 하나의 수단이 될 수 있다.

기술의 발전 속도가 빠르게 변화하는 가운데 인문학 연구자들이 그 속도를 앞서거나 발맞춰 따라가는 것은 쉬운 일이 아니다. 수많은 기술적 선택지 속에서 인문학 연구자가 어떤 항법으로 이 거대한 기술의 우주를 항해할 수 있을지를 모색하기 위해 김초엽 소설의 한 부분을 가지

13 조은경, 2024, 앞의 책, 177쪽.

고 논의해 보고자 한다.

김초엽의 「우리가 빛의 속도로 갈 수 없다면」은 빛의 속도로 이동하거나 그보다 더 빠르게 이동하기를 욕망해 온 인류가 그 욕망의 한계에 도달한 어느 먼 미래의 시점에서 이야기를 시작한다. 우주 곳곳에 세워진 정거장들은 인간이 기술적으로 빛의 속도를 추월한 성과를 보여주지만 한편으로 그 성과에서 밀려난 우주 정거장으로서 ‘슬렌포니아’라는 곳이 주목된다. 이 정거장은 빛의 속도를 초월하는 최신 항법으로는 도달할 수 없으며 오히려 워프 항법이라는 오래되고 낙후된 방식으로만 접근할 수 있는 곳이다. 슬렌포니아는 기술이 모든 것을 가능하게 하리라는 인간의 믿음, 우주 전체를 손아귀에 넣고자 하는 인간의 욕망과 상상력의 한계를 드러내는 장치로 기능한다. 우주 공간에는 인간이 빛의 속도를 추월하는 과정에서 만들어낸 수많은 잔해들이 ‘데브리(debris)’로 부유하고 있으며, 이 폐기된 기술에는 기술 진보의 서사에서 배제된 감각들, 탈락한 존재들, 잊혀진 가능성이 함께 포함되어 있다.¹⁴

슬렌포니아로 향하는 무모한 여정을 감행하는 낡은 항법의 개발자 안나 역시 일종의 데브리이다. 그녀에게서는 “오래전 기술이 되어버린 그것의 부산물인” “희미한 유기물질의 냄새”가 난다. 이 냄새는 기술에서 밀려난 자가 지닌 기억과 감각을 담고 있다.

디지털인문학은 인문학이 갖고 있는 오래된 책의 냄새와 바래진 잉크에서 묻어나오는 글자부터 웹상에서 생성되고 소멸되는 비물질적인 언어들까지를 아우르는 스펙트럼 속에서 작동한다. 그런 의미에서 디지털인문학이란 공간은 퇴장한 언어들이 떠오를 수 있는 낡은 항법이 여전

14 김초엽, 2019, 「우리가 빛의 속도로 갈 수 없다면」, 『우리가 빛의 속도로 갈 수 없다면』, 허블, 145~188쪽.

히 필요하며 동시에 최신의 생성형 언어 모델이 생산한 문장들이 유명하는 우주 실험장일 필요가 있다.

조은경은 이와 같이 서로 다른 시공간 속에서 생산된 텍스트와 기술을 연결하여 데이터 분석의 스펙트럼을 펼쳐 보인다. 2장과 3장에서는 근현대 잡지를 대상으로 필자별 주제 분포와 언어 사용 양상을 통해 잡지의 ‘비동시적 근대성’을 드러낸다. 이 과정에서 단순한 한글 사용 비율 산출에서부터 토픽 모델링, 상호정보량(MI), K-평균 군집분석 등 다양한 정량적 기법이 사용된다. 4장에서는 한국전쟁 당시 2년이 넘는 기간 동안 작성된 휴전회담록 전체를 분석 대상으로 삼아 텐서플로우(TensorFlow)와 허깅페이스(Hugging Face)의 트랜스포머 기반 언어모델을 활용한 발화자 분류 코드를 구현한다. 이를 통해 문서에 담긴 국제 정세와 미국과 남한의 비대칭적 관계, 공산군 측의 담화 전략, 회담 과정에서 협상에 결정적인 영향을 미친 문장들을 효과적으로 추출해 분석하고 있다. 5장에서는 ‘페미니즘’이라는 단어가 포함된 한국어 트윗 멘션을 대상으로 ngram 분석을 실시하며 특히 한국어 멘션의 바이그램에서 성별 대립 구도가 영어권과 다르게 뚜렷하게 드러나는 양상을 밝혀낸다. 마지막 6장에서는 생성형 언어모델의 윤리 문제를 중심으로, AI가 비윤리적 언어를 식별하고 윤리적 언어 표현을 학습할 수 있도록 정밀학습을 통해 조정하는 방식을 탐색하고 있다.

이처럼 이 책은 1932년에 창간된 『한글』에서부터 현재 SNS 상의 멘션, 최신 AI언어모델까지, 시간적으로는 근대 초기부터 최근까지, 기술적으로는 정적 통계부터 딥러닝 기반 언어모델까지 폭넓게 아우르며 텍스트와 기술을 엮어낸다. 특히 과거의 텍스트와 동시대 텍스트를 다루면서 분석 대상의 성격에 적합한 기술을 선택하고 배치하고 있다는 점이 인상 깊다. 최신 기술이라고 해서 우선되지 않으며 오래된 방식이라도

텍스트의 의미를 드러내기에 적절하다면 적극적으로 채택된다. 단순한 통계량 계산이나 ngram 분석처럼 비교적 접근이 쉬운 기술도 그것이 분석 목적에 부합할 경우 유용하게 활용된다. 조은경은 이 책을 통해 기술에 대한 풍부한 감각을 확보하고 분석의 맥락에 따라 기술을 사유하는 능력이 중요하다는 점을 보여주고 있다. 텍스트와 기술 사이의 창조적인 매핑을 도모하는 것, 이를 통해 해석과 판단이 개입된 지식 생산의 실천으로 나아가는 것이 디지털인문학, 인문데이터과학이 추구하는 방향성이라는 것이다.

하지만 여기서 추가적으로 텍스트와 기술 사이를 잇는 데이터셋 구축의 문제를 짚어볼 필요가 있다. 조은경의 책은 주로 토큰화를 거친 후의 데이터 분석 방법에 상대적으로 더 많은 지면을 할애하고 있다. 하지만 텍스트 데이터를 구조화하는 방식은 토큰화에만 국한되지 않는다. 문자열을 속성 칼럼 단위로 구분한 표 형식으로 변환하는 것을 통해서도 정형성을 획득할 수 있다. 이때 일정한 속성 값에 따라 텍스트가 정리된 구조를 데이터셋이라 부른다. 텍스트를 어떤 기준으로 분절하고 어떤 정보를 포함하거나 배제할지, 어떤 형식으로 구조화할지는 텍스트를 바라보는 연구자의 해석적 시각에 기반한다. 즉 데이터셋을 어떻게 구성할 것인가의 문제는 텍스트를 분석하는 연구자의 분석 방향성과 실천의 영역을 투영하고 있다. 특히 인문학 텍스트는 의미의 층위가 복잡하기 때문에 ‘무엇을 문제로 삼고 어떻게 의미화할 것인가’에 대한 연구자의 시각이 반영된 데이터셋은 그 자체로 해석의 층위가 된다. 그런 의미에서 데이터셋은 텍스트를 독해하려는 인문학자의 문제의식과 해석적 개입이 가장 선명하게 드러나는 2차 텍스트라고 할 수 있다.

데이터셋의 행렬 구조는 텍스트를 일정한 서사 단위로 분절하도록 유도한다. 분절된 텍스트는 더 이상 연속적 이야기의 흐름이 아니라 특정

기준에 따라 잘게 쪼개진 조각들의 집합으로 재구성된다. 그리고 이 구조화 과정은 개념화(conceptualization)와 조작화(operationalization)를 필수적으로 수반한다. 개념화는 연구자가 분석하고자 하는 대상으로부터 어떤 속성(attribute)을 주요 개념으로 설정할 것인지를 정의하는 과정이다. 조작화는 그렇게 설정된 개념을 판별할 수 있도록 구체적으로 수치화하거나 명목화하는 절차이다.¹⁵ 처음부터 연구자의 질문에 호응할 수 있는 데이터셋을 구축하는 것은 매우 어렵다. 연구자는 자신이 설정한 개념들이 자신의 질문을 제대로 반영하고 있는지를 지속적으로 점검하면서 그것을 반복적으로 수정하고 보완하는 메타적 과정을 동반하게 된다. 이처럼 데이터셋 구축은 선형적으로 이루어지는 일회성의 작업이 아니라 질문과 해석, 그에 기반한 구조화가 상호작용하는 반복적이고 비선형적인 작업이다. 특히 데이터셋 구축이 반복적이라는 사실은 인문학 텍스트가 지닌 의미의 잠재성이 크기 때문이며 그렇기 때문에 그것을 분절하고 명명하고 수치화하는 행위가 쉽지 않다는 것을 보여준다. 다양한 해석의 가능성을 품고 있는 텍스트 앞에서 연구자는 정보를 판단하고 분류하며 분절의 단위를 설정하고 속성을 정의해가는 역할을 수행하게 된다. 텍스트가 갖는 의미적 잠재성으로 인해 개념화, 조작화 과정을 성공적으로 수행했다고 해도 그 결과로 만들어진 데이터셋은 언제나 불완전하고 잠정적인 구조로 남는다. 바로 이러한 불완전성과 가변성이야말로 인문 데이터가 갖는 고유한 성격이다. 인문 데이터는 동일성의 반복이 아니라 해석의 잠재성 속에서 재구성되고 변형될 수 있는 것이다.¹⁶

15 박진호, 2024, 「인공지능 기술을 인문학에 활용한다면?」, 서울대학교인문대학 엮음, 『디지털 시대, 인문학의 미래를 말하다』, 사회평론 아카데미, 201쪽; 심지섭, 2025, 「양적 분석 방법을 통한 한국 문학 연구의 확장 - 디지털 인문학의 동향 및 도전 과제」, 『현대문학의 연구』 85, 한국문학연구학회, 373~374쪽.

서평을 쓰고 있는 필자는 디지털인문학이나 데이터분석이라는 개념 및 이에 대한 실천적인 접근을 통해 디지털인문학 방법론은 텍스트를 분절하고 구조화하며 그것을 메타 언어화하는 과정을 배우는 학문적 훈련이라는 점을 공유하고 싶다. 이러한 실천은 연구자의 정체성 자체를 변화시키는 계기가 되기도 한다. 연구자는 텍스트를 구조화하고 기술과 함께 텍스트를 다시 써나가는 작업을 수행하며, 기술, 데이터셋 등을 매개로 텍스트와 공동 저작적 관계(co-authorship)¹⁷를 형성하게 한다. 100년 전의 텍스트와 데이터셋이라는 2차 텍스트가 상호 작용하며 원텍스트가 다시 쓰여지는 과정에 놓이게 되는 것이다. 이와 같은 과정에서 연구자는 해석자이자 동시에 텍스트 생산자로서 위치하게 되며 텍스트 내부로 깊이 들어가 몰입하는 경험, 기술을 통해 텍스트를 다르게 구성하는 창조적 개입의 기회를 갖게 된다. 이와 같은 연구자와 독자, 독자와 창작자의 경계가 희미해지는 현상은 뉴미디어 환경이 지닌 특성이라고 할 수 있다. 독자는 텍스트 생산과 해석에 하이퍼텍스트 등 다양한 방법으로 개입할 수 있고 연구자 역시 분석과 해석만이 아니라 텍스트 생산 과정에도 참여할 수 있다.

한국 디지털인문학에 대한 전망을 탐색한 글에서 이재연은 텍스트 재구성뿐만 아니라 거대 언어모델을 활용한 생성의 측면을 포함하여 공동저작성의 워크플로우를 다음과 같이 설명하고 있다.

16 전성규, 2022, 「소설의 언어를 데이터로 읽는다는 것 - '한국현대문학데이터분석연구' 강의 사례를 기반으로」, 『인문과학』 84, 성균관대학교인문학연구원, 5~37쪽.

17 이재연은 매켄지(McKenzie) 등의 텍스트 사회학, 최경희의 공동저작성을 참조하여 개발자들 사이의 협업, 텍스트와 인간, 컴퓨터 간의 상호작용 역시 공동저작성의 개념으로 읽을 수 있음을 제시한다. 이재연, 2024, 「한국문학에서 바라본 디지털 인문학의 전망」, 『인공지능인문학연구』 17, 인공지능인문학연구소, 118쪽.

통합체와 계열체 구성의 차이에 관해 Manovich는 이렇게 설명한다. “통합체적 차원의 요소들은 현존(in praesentia)과 연관되어 있는 반면, 계열체적 차원의 요소들은 부재(in absentia)와 관련이 있다.” 즉, 통합체적으로 연결된 문장은 현재 책이라는 물질적 요소 위에서 존재하는 문장이다. 그러나 계열체적 문장들은, 작가의 창작과정에서 고려되었지만 최종 단어나 문장의 선택에 의해 제외된 표현들이다. 따라서 책에서 보이지 않는 문장들, 즉 부재의 영역에만 존재하는 것이고 이 “계열체적 집합은 오직 작가와 독자의 마음속에만 존재한다.” 이러한 계열체적 세계는 뉴미디어적 시각으로 보면, 데이터베이스가 연결된 세계이기도 하다. 박물관이나 도서관같이 정보의 저장과 축적, 가공을 위해 기능하는 데이터베이스는 데이터와 인간 경험을 연결하는 하나의 형식이다. 전통문화가 신화나 종교와 같이 몇몇 선별된 이야기요소로 구성된 잘 정의된 서사를 제시한다면 근대 이후의 문화는 데이터베이스와 데이터베이스의 연결처럼, 엄청나게 많은 정보를 제공하지만, 이를 충분히 묵지 못하는 서사로 형식화된다. 즉, 뉴미디어 시대를 사는 우리에게는 근대시대와는 다른 서사 작법이 요청되는데, 그것은 “데이터베이스를 특정 순서에 따라 연결함으로써, 즉 한 요소로부터 다른 요소로 이끄는 궤적을 디자인함으로써 서사”를 구성한다는 것이다(밀줄 - 인용자).¹⁸

뉴미디어 시대의 서사는 데이터베이스 안의 요소들을 임의적인 순서로 연결하여 구성된다. 데이터베이스에는 수많은 정보가 축적되어 있기 때문에 이들 요소 간의 연결 가능성 역시 지수적으로 증가한다. 여기에 연결 순서까지를 고려한다면 구성 가능한 서사의 경우는 폭발적으로 늘어나게 된다.

18 이재연, 2024, 앞의 글, 128쪽.

이러한 구조를 언어 생성 모델의 환경으로 옮겨 생각해 볼 수 있다. 파라미터는 거대 언어모델 내에서 어휘와 어휘를 연결하는 함수적 매개이며 이러한 연결이 문장을 형성하는 단위가 된다. 파라미터의 수가 많아 질수록 모델이 생성할 수 있는 문장의 수와 구조는 비약적으로 증가하고 그만큼 서사가 분기하고 확장될 수 있는 경로 역시 기하급수적으로 증식한다. 거대 언어 모델이 갖고 있는 토큰의 총량, 이 토큰들이 배열될 수 있는 모든 조합, 그렇게 형성된 모든 문장의 수, 문장 간 의미적 관계를 통해 구성되는 서사 단위의 조합 가능성까지 고려한다면 생성가능한 서사의 총량은 상상을 초월하는 규모에 도달한다. 그리고 그 모든 연결은 오로지 함수적 연산을 기반으로 하기에 생성된 문장에는 인간의 언어 문법이나 의미 체계에서 벗어난 표현이 상당수 포함될 수 밖에 없다.

이때 의미 체계에서 벗어났다는 판단은 결국 인간 언어의 체계 내 규범과 기대에 따라 이뤄진다. 자연스러운 문장이나 그럴듯한 생성의 결과는 비약을 감수하고 말하면 계열체적 연결이 갖는 부재(in absentia)가 현존(in praesentia)으로 전환될 때 생겨난다. 이 전환은 언어 체계 속에서 미처 드러나지 않았던 가능성이 기존 연결성의 체계 안으로 수렴되는 과정이다.

환각현상(hallucination)이라 불리는 오류는 언어적 연결이 인간 언어의 경험적 패턴과 현저히 어긋날 때 판별된다. 연결 양상이 인간 언어의 체계에서 벗어나 비논리적 구조를 보일 때 우리는 이것을 오류로, 잘못된 연결로 간주한다. 하지만 연결성의 적절함에 대한 판단은 단순히 맞고 틀림의 문제에 국한되지 않고 연속체적 판단의 영역이기도 해서 어느 정도의 이탈이 낮섬으로 감지되는가에 따라 해석이 달라질 수 있다. 그리고 낮은 연결성은 기존 의미체계에서 소외되거나 배제되어 있던 가능성, 부재(in absentia)를 드러내는 방식으로 작동할 수 있다. 인간이 이

전에 연결한 적 없는 대상과 대상 사이에 새로운 관계를 만들어냄으로써 언어적 상상력의 확장을 유도하는 계기가 될 수 있는 것이다.

우리는 환경에 규정되어 있다. '유일무이한 개인'은 존재하지 않는다. 우리가 생각하는 것, 떠올리는 것, 욕망하는 것은 대체로 환경으로부터 예측 가능한 것에 지나지 않다. 당신은 당신의 환경으로부터 예상할 수 있는 변수(parameter)의 집합일 뿐이다. 사람들은 '자기가 원하는 것'과 '환경이 자신에게 요구할 것으로 예측되는 것'이 일치할 때 스트레스를 받지 않고 평화롭게 살아갈 수 있다. ... 이는 나쁘지 않다. 다시 말하지만 인간은 그런 생물이다. 그런데도 많은 사람은 오직 한 번뿐인 인생을 유일무이하다고 여기며 살고 싶어 한다. ... 여기에 인간이 고통스러워 하는 큰 모순이 있다(미줄 - 인8자).¹⁹

아즈마 히로키는 기호가 되지 않는 것이 세계에 존재한다는 사실을 알기 위해서는 약하고 느슨한 연결이 필요하다고 말한다. 이는 언어의 규범 안에서 강하게 고정된 인과적 연결이 아니라 비정형적이고 논리가 약한 연결성을 수용할 수 있는 감각, 기호로 전환되지 않는 잉여 세계에 대한 민감성을 요청하는 언표이다. 이와 같은 관점에서 보면 초거대 언어모델의 환각현상은 규범의 경계 너머를 탐색하는 일종의 '약한 연결'로 재해석될 여지를 제공한다.

약한 연결은 인과관계나 통계적 유사성으로 포섭되지 않는 의미 생성의 가능성을 여는 틈이며 이 틈에서 언어는 정상과 오류, 자연스러움과 낯섦의 경계를 횡단하는 상상력의 공간을 획득하게 된다. 생성형 언어모델을 정밀조정한다는 것은 다른 한편으로 기계를 인간이 이해하고 수용

19 아즈마 히로키, 2016, 『약한 연결』, 안천 역, 북노마드, 11쪽.

할 수 있는 방식으로, 인간이 쌓아온 지식 체계에 부합하는 방향으로 섬세화해 나간다는 것이다. 이러할 때 우발성이나 비논리성은 제거의 대상이 된다. 그러나 디지털인문학은 기계적 언어가 만들어낸 우발성, 낯설, 예측불가능성을 해석의 대상으로 수용하고 이를 통해 인간 언어 체계 바깥 즉 아직 도래하지 않은 언어에 대한 징후를 탐색하는 작업으로 나아갈 필요가 있다.

4. 함수($y=f(x)$)의 문장들과 비극의 가능성

마지막으로 표상의 문제를 다뤄보고자 한다. 조은경은 책 곳곳에서 언어에서 숫자로 표상을 바꾸는 과정 즉 “사람의 자연어를 컴퓨터가 처리하는 부호(code)로 만드는” 인코딩(encoding)의 의미를 중요하게 기입하고 있다. 오늘날에는 코딩이라는 용어가 사회에서 매우 일상적으로 쓰이고 있지만 사실 이것은 표상 방식의 전환이라는 중요한 철학적 행위를 담고 있다. 인간의 언어를 기계의 언어로 바꾸는 과정 전체를 인코딩이라 하며 이것을 통해 자연어는 기계언어라는 새로운 기호 체계 안으로 진입할 수 있으므로 인코딩을 일종의 번역적 행위라 볼 수 있다.

컴퓨터는 기본적으로 모든 명령과 데이터를 수치화된 부호로 처리한다. 자연어의 총량이 시간에 따라 지속적으로 증가하고 변화하듯, 전 세계의 다양한 문자 체계 아래서 형성된 언어 표현을 컴퓨터가 읽을 필요가 있게 됨에 따라 보다 포괄적인 문자 인코딩 체계가 필요하게 되었다. 이러한 배경에서 등장한 것이 유니코드(Unicode)이다. 유니코드는 전 세계 언어 문자를 하나의 통합된 코드 체계로 다루는 문자 인코딩 표준이다.²⁰ 민족어, 모어, 국어, 종족어 등 다양한 언어 자질들을 디지털 공간

안에서 소통하게끔 하는 언어로서 유니코드는 일종의 디지털 세계의 보편언어라고 부를 수 있다.

구체적인 번역의 과정은 다음과 같다. 자연어는 토큰화를 거쳐 단위로 분절된 후 고유한 아이디(ID) 값을 부여 받는다. 이후 기계는 대규모 말뭉치를 기반으로 이 ID들 사이의 연관성을 학습하며 각 단어의 사용 맥락에 따라 해당 단어의 의미를 숫자들의 나열 즉 벡터(vector)로 표현한다. 이 과정을 워드 임베딩(word embedding)이라 한다. 단어 수준에서 시작하여 문장, 문맥 수준에서 임베딩을 거치면서 텍스트는 하나의 구조화된 지식으로 처리될 수 있다. 여기서 코드, ID, 벡터는 기호학적 관점에서 시니피앙(signifiant)으로, 이들이 지시하는 자연어 또는 문장은 시니피에(signifié)로 이해될 수 있다. 이 둘은 신경망 구조 안에서 노드와 노드 간 연결 강도, 즉 파라미터 값으로 모델링된다.

시니피앙과 시니피에의 자의적 관계는 기계학습 기반 임베딩 구조에서도 확인할 수 있다. 예를 들어 ‘문학’이라는 시니피앙이 시대나 지역에 따라 서로 다른 시니피에와 결합되어 온 것처럼 단어는 고정된 하나의 벡터값을 갖는 것이 아니라 문맥에 따라 그 벡터가 동적으로 변화한다. 이때 파라미터는 언어의 의미가 맥락 속에서 변화하고 재구성되는 과정을 수치화하는 매개로서 이는 데리다가 말한 의미의 차연(différance)을 기술적으로 구현하는 장치로도 해석될 수 있다.

텍스트의 즐거움은 고전·문화·지성·아이러니·섬세함·행복감·자제력, 삶의 기술적인 안정감이다. 텍스트의 즐거움은 실천[어떤 억지(répression)의 위험도 없
 닐에 의해 정의될 수 있다. ... (인용자) 자아의 놀라운 강화(팡타즘에 의해), 포근

한 무의식. 이런 즐거움은 말해질 수 있다. 바로 거기로부터 비평이 온다.

즐김의 텍스트는 조각난 즐거움, 조각난 언어, 조각난 문화이다. 그것은 상상할 수 있는 모든 궁극성 — 즐거움의 궁극성조차도 — 밖에 위치한다는 점에 서 변태적이다(즐김은 즐거움을 강요하지 않는다. 그것은 표면적으로 지루하게 할 수도 있다). 어떤 알리바이도 성립되지 않으며, 어떤 것도 재구성되거나 회수되지 않는다.즐김의 텍스트는 절대적으로 자동사적이다. 그러나 단순한 변태/뒤집음 만으로는즐김을 정의하기에 충분치 않다.즐김을 정의하는 것은 극단적인 변태이다. 언제나 극단적인 이동, 극단적인 공허, 극단적인 유동성, 극단적인 예측불능. 이 극단적인 것이즐김을 보장한다. 평범한 변태/뒤집음은 이내 하위의 궁극성의 유희로 채워진다. 즉 명성이며 선전·경쟁·담론·과시 등으로.²¹

바르트는 『텍스트의 즐거움』에서 텍스트의 즐거움과즐김의 텍스트를 구분한다. 텍스트의 즐거움(plaisir)은 “욕구가 편안해지도록 기도함으로써 얻어지는 즐거움”으로 안락하고 익숙한 감각을 제공하며 독자를 이해가능한 독서로 이끈다. 이러한 텍스트는 자아를 통합하고 회복시키며 독자는 이 과정을 통해 자의식을 강화하게 된다. 대표적으로 고전 문학이나 문학 정전이 이와 같은 역할을 수행한다. 반면즐김(jouissance)의 텍스트는 텍스트, 언어, 문화를 조각내는 파편화의 과정을 수반하며 그 행위 자체가 목적이 된다. 그 속에서는 어떤 것도 “재구성되거나 회수되지 않는다.”즐김은 불가역적인 활동이며 불가역성을 극단까지 밀어붙인 행위이다. 바르트는 극단적으로 변형되어 다시 돌아갈 수 없는 형태가 된 것, 그것을 ‘슈이상스’라고 정의한다. 일정 수준의 변형은 탄성을 가지고 있으므로 하위의 유희인 반면 극단적인 변형은 “절대적으로 자

21 롤랑 바르트, 2022, 『텍스트의 즐거움』, 김희영 역, 동문선, 90~91쪽.

동사적이”라는 점에서 분명한 차이가 있다. 목적어를 갖지 않는 자동사처럼 즐겁의 텍스트는 목적을 갖지 않는다. 의미 전달이나 해석 가능성이라는 목적을 거부하거나 유예한다. 바로 그러한 이유로 즐겁의 텍스트는 독자에게 불편함과 충격을 주며 논리로 환원되지 않는 감각적 파편과 해체를 드러내 보인다.

프랑코 모레티는 자본주의 세계에서 문학의 역할을 “모순적 긴장들을 제거하는 것이 아니라 완화시킬 수 있는 영역을 창조해 분열에 대한 인식 자체를 그것을 감내해야 하는 사람들을 ‘행복하게’ 만드는 방식으로 재조직하는 것”이라고 말한다.²² 이것은 상충되는 가치들의 화해를 이끌어냄으로써 가능하며 그렇기에 “타협이 ‘리얼리즘적’ 서사 문학의 위대한 주제”가 된다. 문학은 상충되는 가치들을 ‘조정’하는 역할을 담당한다. “프로이트는 예술을 문명이 개인들에게 희생하도록 강요하는 충동에 대한 가장 성공적인 형태의 ‘보상’으로 간주했다.”²³ 바로 이러한 사실이 현대에 비극이 불가능한 이유가 된다. 비극은 타협불가능한 갈등을 끝까지 밀어붙여 삶의 진리를 열어 보인다. 반면 문학은 진리의 순간에 다가가다가도 “즉각 공포에 사로잡혀 일상의 마취된 리듬 속으로 움츠러든다.” 그런 의미에서 “현대 비극의 불가능성이 최고의 현대적 비극이다.”²⁴

바르트는 문장은 완결된 형식을 갖추고 있지만 그 완결성은 강제된 것이라고 말한다. 사회는 문장이 종결되도록 요구한다. 그는 “모든 이데올로기적 행위는 구성상 완결된 언표의 형태로 제시된다.”라는 크리스

22 프랑코 모레티, 2014, 『공포의 변증법』, 조형준 역, 새물결, 440쪽.

23 프랑코 모레티, 2014, 앞의 책, 438쪽.

24 프랑코 모레티, 2014, 앞의 책, 357쪽.

테바의 말을 인용하여 “모든 완결된 언표는 이데올로기적인 것이 될 위험이 있다”고 지적한다.²⁵ 모레티가 말한 비극이 불가능한 문학, 조화와 화해의 방법을 고민하는 문학은 바르트적 의미에서 닫힌 문장이며 즐거움(plaisir)의 문학이다. 닫힌 문장은 기표와 기의의 미끄러짐을 멈추고 해석의 잠재성을 중단시키는 힘이다.

그러나 문장은 “원칙상 무한한 것”²⁶일 수 있다. 바르트는 문장 자체를 계속 쓰이고 싶은 욕망을 가진 ‘구조’로서 파악한다. 그것은 ‘주이상스로서 텍스트’의 의미와 상통한다. 그리고 기계는 문장을 종결하지 않을 수 있다. 기계는 의미를 끝맺는 문학과 예술의 의례를 따르지 않을 수 있다. 비록 현실에서 구현될 때에는 문장이 일시적으로 종결될 수 있어도 그것은 단지 연산의 일시적인 중지일 뿐 연산의 완결은 아니다.

언어 모델들이 만들어내는 텍스트는 인간이 해석할 수 있는 문장처럼 보이지만 그 생성의 동력은 의미가 아니라 확률과 통계적 연관성에 기반한다. 그리고 그것을 인간이 읽을 수 있는 것은 모델이 인간의 언어 ‘패턴’을 학습함으로써 인간이 이해할 수 있도록 출력을 정렬하기 때문이다. 만약 이러한 학습이 없거나 최소화된다면, 기계는 때로는 말이 되지 않는 문장을 생성하고, 타협없이, 중단없이, 무한히 반복하고 이어 붙이는 생성 행위를 지속할 수 있다. 바로 이 지점에서 ‘새로운 문학’의 가능성을 생각해 볼 수 있다. 갈등과 모순을 조율하고 타협하며 상처를 봉합하는 문학이 아니라 조율되지 않는 파열 속에서 의미로서 수습되지 않는 언어의 조각들이 무작위로 배치되는 것을 묵도하며 새로운 문학에 대한 감각을 버릴 수 있지 않을까. 그런 의미에서 비극은 더 이상 쓰이

25 롤랑 바르트, 2022, 앞의 책, 88~89쪽.

26 롤랑 바르트, 2022, 앞의 책, 88쪽.

지 않는 것이 아니라 다른 방식으로 우리에게 도달하고 있는 중인지도 모른다.

5. 결론

조은경의 『한국학과 데이터과학』은 “어문 및 인문학 연구자에게 활용도 높은 데이터과학적 연구방법론을 안내함으로써” 한국 문학 및 문화 연구를 디지털인문학 방법론을 수행하고자 하는 연구자에게 실질적인 도움을 줄 수 있는 책이다. 디지털인문학은 데이터 분석의 프로토콜을 포함하지만 단순한 기술 활용을 넘어 철학적, 문화적 전환을 내포하는 광범위한 개념으로 사용되기도 한다. 이 과정에서 생산되는 관련 논문이나 논의들은 담론성이 강하게 나타나거나 기술 사용 과정이 간소화되는 경우가 있는 것도 사실이다. 조은경은 ‘데이터과학’이라는 용어를 채택함으로써 한국어 기반 언어 자료를 수집하고 처리하여 분석하는 데 필요한 구체적인 기술과 절차에 보다 초점을 맞추고 있다.

디지털인문학에서 가장 활발하게 수행되는 연구 중 하나는 문자 기반 텍스트에 대한 분석이다. 그렇기 때문에 이 책 또한 “데이터의 양적 분석에 쓰이는 기초 통계량에서부터 딥러닝에 이르기까지”를 차근차근 설명하고 있다. 비정형 데이터의 비중이 증가함에 따라 평균, 표준편차, 분산 등 전통적인 기술통계량만으로는 데이터가 내포한 복잡한 의미 구조나 맥락적 관계를 충분히 설명하기 어려운 점이 있으므로 고차원 벡터 기반 지표들을 요청하게 되었으며 더 나아가 딥러닝 언어모델에 기반하여 “문맥에 따라 벡터 값이 변하는 동적 벡터”를 활용, 단어 수준을 넘어 문장, 문맥, 최종적으로 텍스트 수준에서 의미가 생성되는 과정을 다차

원 벡터 공간에서 정교하게 표현하려는 시도들이 이어지고 있다. 또한 GPT와 같은 생성형 언어 모델을 인문학 연구와 결합하기 위해 RAG이나 온톨로지 기반 모델링을 활용하여 특정 분야의 전문 데이터를 추가 학습함으로써 특정 도메인에 특화된 지식 생성의 정확도를 향상하려는 시도가 활발하다. 이와 같은 지식 생산 모델링은 다양한 지식 파이프라인을 구축하여 그간 인문학이 방대하게 축적해 온 고유의 해석적 실천을 계승하는 동시에 새로운 지식 생산의 잠재성을 지닌 연구 인프라로 역할할 수 있다.

저자가 데이터과학의 방법론적 변화 과정을 서술하는 흐름을 따라가다 보면 이는 곧 디지털인문학의 자기 갱신 과정임을 알게 된다. 정적 언어 모델에서부터 동적 언어 모델로의 이행, 초대규모 언어 모델의 인문학적 활용 방식에 대한 모색은 인문학 텍스트가 지닌 의미적 중층성을 중심에 두고 기술을 비판적으로 사유하는 자세에서 비롯된 것이다. 그러나 이러한 이행 과정을 거친다고 해서 최신의 기술만이 활용되는 것은 아니다. “정적 단어 임베딩이 최신의 인공지능 언어 모델에서는 다소 유행에 뒤떨어진 감이 있지만 단히 정적 데이터 집합을 다룬다는 점에서 언어학적으로 인문학적으로는 여전히 살펴볼 여지가 많은 방식”이라는 조은경의 지적처럼 정적 언어 모델링은 동적 언어 모델이 포착하기 어려운 의미구조를 안정적으로 확보하는 데 유용하게 역할할 수 있다. 기술의 발전 속도가 빠르게 변화하는 가운데 인문학 연구자들이 그 속도를 앞서거나 발맞춰 따라가는 것은 쉬운 일이 아니다. 오히려 조은경은 인문학연구자가 기술에 대한 풍부한 감각을 확보하고 분석의 맥락에 따라 기술을 사유하는 능력이 더 중요하다는 점을 보여주고 있다. 텍스트와 기술 사이의 창조적인 매핑을 모색하고 이를 통해 해석과 판단이 개입된 지식 생산의 실천으로 나아가는 것이 디지털인문학, 인문데

이티과학이 추구하는 방향성이라는 것이다.

이와 같은 흐름을 따라가며 서평을 쓰는 필자는 추가적으로 데이터셋 구성의 중요성과 텍스트가 기술, 데이터셋 등을 통해 새롭게 표상됨으로써 열리는 글쓰기의 가능성, 연구자의 정체성 변화에 대해 언급하였다. 텍스트를 대상으로 데이터셋을 구축하는 과정은 텍스트를 어떤 기준으로 분절하고 어떤 정보를 포함 혹은 배제할 것이며, 어떤 형식으로 이를 구조화할 것인지를 고민하는 과정으로 그 자체로 텍스트를 적극적으로 읽는 행위이다. 연구자는 데이터셋 구축 과정에서 이루어지는 개념화와 조작화의 과정을 거쳐 2차 텍스트를 생산하는 저자가 된다. 데이터셋은 2차 텍스트라고 할 수 있다. 이와 같이 디지털인문학 연구는 공동 저작성의 워크플로우를 포함하고 있기 때문에 이 과정에서 연구자와 독자, 독자와 창작자의 경계는 희미해진다.

연구자가 텍스트를 구조화하기 위한 체계를 마련하거나 데이터셋을 구축한 뒤에는 기술적 개입이 뒤따른다. 인간의 언어를 컴퓨터가 처리할 수 있는 코드로 변환하는 번역적 과정을 거친 이후 컴퓨터는 연산을 통해 분석 단위 사이의 관계를 파악한다. 시니피앙과 시니피에의 자의적 관계는 기계학습 기반 임베딩 구조에서도 확인할 수 있다. 예를 들어 ‘문학’이라는 시니피앙이 시대나 지역에 따라 서로 다른 시니피에와 결합되어 온 것처럼 단어는 고정된 하나의 벡터값을 갖는 것이 아니라 문맥에 따라 그 벡터가 동적으로 변화한다. 이때 파라미터는 언어의 의미가 맥락 속에서 변화하고 재구성되는 과정을 수치화하는 매개로서 이는 데리다가 말한 의미의 차연(différance)을 기술적으로 구현하는 장치로도 해석될 수 있다.

의미의 차연은 연산 모델에서 구현 가능하다. 문장은 “원칙상 무한한 것”일 수 있다. 바르트는 문장 자체를 계속 쓰이고 싶은 욕망을 가진 ‘구

조'로서 파악한다. 그것은 '주이상스(jouissance)'로서 텍스트의 의미와 상통한다. 기계는 문장을 종결하지 않을 수 있다. 기계는 의미를 끝맺는 문학과 예술의 의례를 따르지 않을 수 있다. 비록 현실에서 구현될 때에는 문장이 일시적으로 종결될 수 있어도 그것은 단지 연산의 일시적인 중지일 뿐 연산의 완결은 아니다.

언어 모델들이 만들어내는 텍스트는 인간이 해석할 수 있는 문장처럼 보이지만 그 생성의 동력은 의미가 아니라 확률과 통계적 연관성에 기반한다. 그리고 그것을 인간이 읽을 수 '있는' 이유는 모델이 인간의 언어 패턴을 학습함으로써 인간이 이해할 수 있도록 출력을 정렬하기 때문이다. 만약 이러한 학습이 없거나 최소화된다면, 기계는 때로는 말이 되지 않는 문장을 생성하고, 타협 없이, 중단 없이, 무한히 반복하고 이어 붙이는 생성 행위를 지속할 수 있다. 바로 이 지점에서 '새로운 문학'의 가능성을 생각해 볼 수 있다. 갈등과 모순을 조율하고 타협하며 상처를 봉합하는 문학이 아니라 조율되지 않는 파열 속에서 의미로서 수습되지 않는 언어의 조각들이 무작위로 배치되는 것을 목도하며 새로운 문학에 대한 감각을 베풀 수 있지 않을까. 그런 의미에서 비극은 더 이상 쓰이지 않는 것이 아니라 다른 방식으로 우리에게 도달하고 있는 중인지도 모른다.

접수일(2025.05.17.), 심사 및 수정일(1차 2025.06.13., 2차 2025.06.19.), 게재확정일(2025.06.20.)

참고문헌

〈기본 자료〉

조은경, 2024, 『한국학과 데이터과학』, 서강대학교출판부.

〈단행본〉

김초엽, 2019, 『우리가 빛의 속도로 갈 수 없다면』, 허블.

롤랑 바르트, 2022, 『텍스트의 즐거움』, 김희영 역, 동문선(Roland Barthes, 1973, *Le plaisir du texte*, Paris: Éditions du Seuil).

아즈마 히로키, 2016, 『약한 연결』, 안천 역, 북노마드(東浩紀 2014, 弱いつながり一検索ワードを探す旅 幻冬舎).

프랑코 모레티, 2014, 『공포의 변증법』, 조형준 역, 새물결(Franco Moretti, 1988, *Signs taken for wonders: essays in the sociology*, NewYork: Verso).

〈논문〉

강우규·김바로, 2024, 「국문장편소설의 감정에 대한 정성적·정량적 연구 시론 - 「창선감의 록」과 「소현성록」을 중심으로」, 『고소설연구』 58, 한국고소설학회, 223~258쪽.

김병준·노대원, 2025, 「생성형 AI는 인문학 연구를 어떻게 바꿀까?」, 『영주어문』 59, 영주어문학회, 203~227쪽.

김일환·이도길, 2020, 「개화기 잡지 코퍼스의 구축과 율용」, 『개념과 소통』 25, 한림대학교 한림과학원, 5~31쪽.

도재학, 2022, 「『한국근대잡지코퍼스』의 언어학적 가치」, 『개념과 소통』 29, 한림대학교 한림과학원, 7~43쪽.

박진호, 2024, 「인공지능 기술을 인문학에 활용한다면?」, 서울대학교인문대학 여름, 『디지털 시대, 인문학의 미래를 말하다』, 사회평론 아카데미, 213~240쪽.

배용준, 2025, 「검색증강생성(RAG)에 관한 국내 연구 동향」, 『한국융합학회지』 14, 한국융합과학회, 407~421쪽.

심지섭, 2025, 「양적 분석 방법을 통한 한국 문학 연구의 확장 - 디지털 인문학의 동향 및 도전 과제」, 『현대문학의 연구』 85, 한국문학연구학회, 361~395쪽.

- 어수경·박찬준·문현석·임희석, 2021, 「한국어 인공지능경망 기계번역의 서브 워드 분절 연구 및 음절 기반 종성 분리 토론회 제안」, 『한국융합학회논문지』 12, 한국융합학회, 1~7쪽.
- 이성우, 2022, 「『한국근대잡지코퍼스』로 엿보는 한국의 근대: 키워드와 빈도를 중심으로」, 『개념과 소통』 29, 한림대학교, 한림과학원, 45~79쪽.
- 이유미·김바로, 2022, 「사회 네트워크 분석을 활용한 1930년대 후반 동인지시(詩誌)와 시인」, 『인문논총』 79, 인문학연구원, 212~245쪽.
- 이재연, 2016a, 「키워드와 네트워크: 토픽모델링으로 본 『개벽』의 주제 지도 분석」, 『상허학보』 46, 상허학회, 277~334쪽.
- _____, 2016b, 「『생활』과 『태도』 기계가 읽은 『개벽』과 『조선문단』의 작품 비평어와 비평가」, 『개념과 소통』 18, 한림대학교 한림과학원, 5~52쪽.
- _____, 2024, 「한국문학에서 바라본 디지털 인문학의 전망」, 『인공지능인문학연구』 17권, 인공지능인문학연구소, 113~138쪽.
- 전성규·김병준, 2019, 「디지털인문학 방법론을 통한 『서북학회』와 『태극학보』의 담론적 상관관계 연구」, 『개념과 소통』 23, 한림대학교 한림과학원, 141~188쪽.
- 전성규, 2022, 「소설의 언어를 데이터로 읽는다는 것 - ‘한국현대문학데이터분석연구’ 강의 사례를 기반으로」, 『인문과학』 84, 성균관대학교인문학연구원, 5~37쪽.
- _____, 2024, 「이광수의 오감(五感) 오케스트레이션 - 소리 데이터 생산과 미디어 교차 중심으로」, 『춘원연구학보』 29, 춘원연구학회, 73~109쪽.
- 허수, 2018, 「언어연결망 분석으로 본 20세기 초 한국의 ‘문명’과 ‘문화’: 주요 언론 기사에서의 논의 맥락을 중심으로」, 『개념과 소통』 22, 한림대학교 한림과학원, 241~279쪽.
- 홍정욱·김기덕, 2014, 「2014 세계 디지털인문학’ 학술대회 및 한국의 디지털인문학」, 『인문콘텐츠』 34, 인문콘텐츠학회, 53~75쪽.

〈기타 자료〉

<https://www.kadh.org/2025-디지털인문학-겨울학교/>

<https://github.com/searle-j/KOTE>

<https://excessive-fowl-713.notion.site/feat-RAG-136708dbce8780109023d574f5253496>

Abstract

From Static Language Models to AI
: On the Technique of Rewriting Texts
— A Review of *Korean Studies and Data Science*
(Eunkyoung Cho, 2024, Sogang University Press) —

Seongkyu Jeon*

■ **Keywords:** data-scientific research methods, digital humanities, static language model, dynamic language model, generative language model, knowledge production modeling, creative mapping between text and technology, multi-layered co-authorship, unending writing, *différance*

Eunkyoung Cho's *Korean Studies and Data Science* is a book that offers practical guidance for researchers in Korean literature and culture who wish to engage in digital humanities methodologies by introducing “data-scientific research methods highly useful for language and humanities scholars.” While digital humanities encompass protocols of data analysis, the term is also broadly used to signify a philosophical and cultural shift beyond mere technological application. As a result, many scholarly discussions in this field tend to take on strong discursive tendencies, and at times the technical processes involved are overly simplified. By using the term “data science,” Cho explicitly emphasizes the concrete technologies and procedures necessary for collecting, processing, and analyzing Korean language-based textual data.

One of the most active areas of digital humanities research is the analysis of

* College of AI Humanities, Gachon University.

text-based, written materials. Accordingly, this book systematically explains everything “from basic statistical measures for quantitative data analysis to deep learning.” As the proportion of unstructured data increases, traditional descriptive statistics such as mean, standard deviation, and variance are no longer sufficient to explain the complex semantic structures or contextual relationships embedded in data. This has led to a growing use of high-dimensional vector-based metrics. Furthermore, deep learning-based language models now make it possible to express meaning across not only word-level but also sentence-level, context-level, and full-text levels using dynamic vectors whose values shift according to context.

Efforts are also underway to integrate generative language models such as GPT into humanities research. Techniques such as Retrieval-Augmented Generation (RAG) or ontology-based modeling are actively employed to fine-tune models using domain-specific datasets, thereby enhancing the precision of knowledge generation tailored to particular research areas.

As one follows Cho’s account of the methodological evolution in data science, it becomes apparent that this trajectory reflects the digital humanities’ own process of self-renewal. The transition from static to dynamic language models and the exploration of how large-scale language models can be applied to the humanities arise from a critical stance that centers the semantic multilayeredness of humanistic texts. In an era where technological advancements move at a rapid pace, it is difficult for humanities researchers to stay ahead of or even keep up with such developments. Rather than racing to match that pace, Cho argues, what is more crucial is the ability to develop a rich sensibility toward technology and to think critically about it in context. Her book underscores that what digital humanities—and data-driven humanities in particular—ultimately aim for is a

practice of knowledge production shaped through creative mapping between text and technology, with interpretation and judgment deeply embedded in the process.

Following this trajectory, the reviewer further emphasizes the importance of dataset construction, the new possibilities of writing that open up when texts are re-represented through technology and data structures, and the shifting identity of the researcher. Digital humanities research involves workflows of co-authorship across multiple levels—between technology and researcher, and between text and researcher. Moreover, the infinite capacity of machine-generated text allows for the exploration of new writing styles that deviate from the conventions of closure that dominate traditional literature and art. These texts may sometimes consist of language fragments that hover at the boundaries of meaning, defying established norms. In witnessing the disorder of language pieces that resist interpretive cohesion and are arranged at random, we begin to sense the opening of a path toward imagining new forms of literature.